

WIN — IBOVESPA FUTURO · B3

Plano Mestre de Pesquisa Quantitativa

Classificação Binária da Direção do Candle Diário

XGBoost · TFT · Decisão no Fechamento D-1 · Regime-Aware

Versão 1.0 · Maio 2026

Sumário Executivo

Este documento descreve o plano completo de pesquisa quantitativa para prever a direção do candle diário do WIN (Ibovespa Futuro). O modelo toma a decisão uma vez por dia, no fechamento do pregão anterior (D-1), usando informações completamente disponíveis naquele momento.

O WIN tem dinâmica estruturalmente diferente do WDO e exige tratamento específico em três frentes: (1) viés de alta secular que cria desbalanceamento de classes, (2) regime shifts de longo prazo que invalidam modelos treinados em ciclos distintos, e (3) transmissão assimétrica de risco global — quedas do SPX afetam o WIN com mais intensidade e velocidade do que altas.

Parâmetro	Definição
Ativo	WIN — Ibovespa Futuro Mini (B3)
Problema	Classificação binária: dia de alta (0) vs dia de baixa (1)
Timeframe do target	Candle DIÁRIO — 1 previsão por pregão
Momento da decisão	Fechamento de D-1 — todas as features disponíveis, sem ambiguidade temporal
Features	Candle diário D-1 + agregados intraday 15min/1H de D-1 + macro D-1
Modelos	XGBoost → TFT (sequencial, condicionado a critérios de performance)
Amostras estimadas	~252 por ano · 4 anos de DEV ≈ 1.000 amostras de treino
Validação	Walk-forward expanding com purge · 5 folds mínimo · regime-stratified
Riscos específicos	Desbalanceamento de classes · Regime shift de longo prazo · Assimetria SPX→WIN
Critério final	Profit factor OOS > 1.3 · Sharpe anualizado > 0.8 · Drawdown < 20%

1. Especificidades do WIN — Por Que Não É Apenas o WDO com Outro Nome

O WIN e o WDO são ativos brasileiros negociados na B3, mas têm dinâmicas fundamentalmente diferentes. Ignorar essas diferenças é a principal causa de modelos que funcionam em backtest e falham fora da amostra.

1.1 Driver Primário: Risco Global, Não Câmbio

Dimensão	WDO	WIN
Driver primário	DXY (dólar global) — o WDO sobe quando o dólar sobe globalmente	SPX/Nasdaq — o WIN cai quando o risco global cai, independente do câmbio
VIX	Fator secundário — afeta pelo canal de emergentes	Fator primário — picos de VIX transmitem diretamente para o WIN via fluxo
DI Futuro	Fator endógeno direto — juros afetam câmbio via carry trade	Fator indireto — juros altos competem com renda variável (custo de oportunidade)
Commodities	Relevante via balança comercial (petróleo, ouro)	Minério de ferro é crítico — Vale representa >10% do Ibovespa
WDO/câmbio	É o próprio ativo	Feature relevante — real fraco = pressão vendedora em bolsa via fluxo estrangeiro
Fluxo estrangeiro	Impacto moderado	Impacto alto — investidor estrangeiro representa ~50% do volume do Ibovespa

1.2 Viés de Alta Secular — Problema de Desbalanceamento

O Ibovespa tem viés de alta estrutural de longo prazo. Em períodos de bull market (2016–2019, 2020–2021), a distribuição de candles diários pode ser 60% alta / 40% baixa ou mais extrema. Isso cria três problemas específicos:

Risco central: Um modelo que aprende apenas o viés de alta do período de treino vai ter acurácia aparentemente alta, mas vai falhar sistematicamente em bear markets. Não é sinal — é viés de amostra.

- Problema 1 — Acurácia enganosa: modelo que prevê 'alta' todo dia terá acurácia de 60%+ em bull market, mas não tem valor preditivo.
- Problema 2 — Threshold viciado: sem calibração explícita, o modelo vai preferir a classe majoritária mesmo quando o sinal aponta para baixa.

- Problema 3 — Fold contaminado: um fold de treino em bull market e teste em bear market vai parecer que o modelo degradou, mas pode ser apenas regime shift.

Estratégias de mitigação obrigatórias:

```
# 1. Medir desbalanceamento por fold e por período
for fold in folds:
    print(fold.target.value_counts(normalize=True))
    print(f'Regime: {identificar_regime(fold)}' # bull / bear / lateral)

# 2. Usar class_weight='balanced' no XGBoost
scale_pos_weight = n_baixa / n_alta # se n_alta > n_baixa

# 3. Usar balanced_accuracy como métrica de ML principal (não acurácia simples)
from sklearn.metrics import balanced_accuracy_score
# balanced_accuracy = média de recall por classe — não se deixa enganar pelo viés

# 4. Avaliar métricas financeiras separadamente em dias de alta e de baixa do SPX
```

1.3 Regime Shift de Longo Prazo — O Maior Risco do WIN

O Ibovespa passou por regimes radicalmente distintos nos últimos anos:

Período	Regime	Características
2016–2019	Bull market / recuperação econômica	Correlação alta com SPX, fluxo estrangeiro positivo, Selic caindo
2020 (Mar)	Crash COVID — queda de 45% em semanas	VIX > 80, fluxo estrangeiro saindo, correlações colapsam
2020–2021	Recuperação V / bull market global	SPX e WIN em alta simultânea, liquidez global abundante
2022–2023	Ciclo de juros altos Brasil e EUA	DI > 13%, custo de oportunidade alto, Ibovespa lateral/pressionado
2024–2025	Novo ciclo — transição de regime	Comportamento distinto dos períodos anteriores

Por que isso importa: Um modelo treinado em 2016–2020 vai aprender a comprar em dips do SPX. Isso funcionava. Em 2022–2023, com Selic a 13%, a dinâmica era diferente: renda variável competia com renda fixa de forma inédita. O modelo precisa identificar em qual regime está operando.

Estratégias de mitigação obrigatórias:

- Feature de regime explícita: criar variável que identifica o regime atual (bull/bear/lateral/juros altos)
- Walk-forward com análise por regime: reportar desempenho separado por tipo de período

- KS test entre folds: detectar quando a distribuição de features muda significativamente entre treino e teste
- Expanding window preferida sobre rolling: inclui mais contexto histórico de regime

1.4 Assimetria de Transmissão SPX → WIN

A correlação entre SPX e WIN não é simétrica. Quedas do SPX transmitem para o WIN de forma mais rápida, intensa e persistente do que altas. Isso tem implicações diretas para o feature engineering:

```
# Não usar só o retorno do SPX - capturar a assimetria explicitamente
df['spx_ret_pos'] = df['spx_ret_d1'].clip(lower=0) # altas do SPX
df['spx_ret_neg'] = df['spx_ret_d1'].clip(upper=0) # quedas do SPX
df['spx_queda_5d'] = df['spx_ret_d1'].rolling(5).sum().clip(upper=0) # quedas acumuladas

# Intensidade do movimento: retorno / volatilidade recente
df['spx_zscore'] = df['spx_ret_d1'] / df['spx_ret_d1'].rolling(20).std()
df['spx_drawdown'] = df['spx'] / df['spx'].rolling(60).max() - 1 # queda do topo recente

# VIX: nível absoluto importa tanto quanto a variação
df['vix_nivel'] = df['vix'] # nível atual
df['vix_spike'] = (df['vix_ret_d1'] > 0.15).astype(int) # alta de > 15% no VIX em 1 dia
df['vix_regime'] = pd.cut(df['vix'], bins=[0,15,20,25,35,100],
                           labels=['baixo','normal','elevado','alto','crise'])
```

2. Definição Formal do Problema

2.1 O Problema Central

Definição: O modelo prevê a direção do candle diário do WIN. Cada linha do dataset é um dia de pregão. A decisão é tomada no fechamento do dia anterior. Não há operação intraday.

```
retorno_dia = (close_D - open_D) / open_D

# Limite adaptativo por volatilidade - nunca menor que o custo estimado
custo_estimado = 0.0004 # ~4 pontos WIN (spread + corretagem)
limite = max(retornos_diarios.abs().rolling(252).quantile(0.30),
             custo_estimado * 2)

target_D = 0   se retorno_dia > limite   # dia de alta
target_D = 1   se retorno_dia < -limite  # dia de baixa
target_D = NaN se abs(retorno_dia) <= limite # zona neutra - excluído
```

Por que o limite adaptativo é crítico para o WIN: O limite adaptativo baseado em quantil rolling é especialmente importante para o WIN: em períodos de alta volatilidade ($VIX > 25$), movimentos de 0.5% são comuns e ruidosos. O limite adaptativo se ajusta automaticamente ao regime, evitando que o modelo aprenda ruído em períodos turbulentos.

2.2 Targets Alternativos para Diagnóstico

ID	Definição	Quando usar
Target A	Retorno open→close do dia D (principal)	Alinhado com quem entra no open e sai no close. Exclui o impacto do gap overnight.
Target B	Retorno close→close (D-1 para D)	Inclui o gap overnight. Mais previsível em dias com eventos macro noturnos (Fed, dados EUA).
Target C	Retorno vol-ajustado: $\text{ret_D} / \text{std_rolling}(20d)$	Normaliza por regime de volatilidade — menos sensível a crashes e períodos de VIX alto. Preferido para comparação entre regimes.
Target D	Direção do fechamento vs abertura: $\text{sign}(\text{close_D} - \text{open_D})$	Versão binária pura sem limite — serve como sanity check mas inclui muito ruído.

2.3 Momento da Decisão e Fluxo de Informação

Informação	Status no fechamento de D-1
Candle diário D-1	OHLCV completo do pregão anterior — disponível

Candles 15min de D-1	Todos os candles intraday do dia anterior — fechados e disponíveis
Candles 1H de D-1	Todos os candles de 1H do dia anterior — fechados e disponíveis
SPX fechamento D-1	Fechamento do S&P 500 — disponível (mercado EUA fecha ~18h Brasília)
VIX fechamento D-1	Nível do VIX no fechamento americano — disponível
DX, US10Y D-1	Fechamentos do mercado americano — disponíveis
DI, WIN spot D-1	Fechamentos do mercado brasileiro — disponíveis
Futuros SPX overnight	Futuros do S&P500 negociados após o fechamento — disponíveis via API, mas exigem dado em tempo real — NÃO usar na versão 1
Open do WIN em D	NÃO disponível — existe apenas no dia seguinte
Notícias de D	NÃO usar — apenas calendário econômico publicado previamente

Nota sobre futuros overnight: Futuros do SPX negociados à noite (após o fechamento americano) são tecnicamente disponíveis no fechamento de D-1, mas exigem dado em tempo real e introduzem complexidade operacional. Deixar para versão 2 após validar o modelo com dados de fechamento padrão.

3. Dataset Base

3.1 Estrutura — Uma Linha por Pregão

Campo	Conteúdo	Regra temporal
date	Data do pregão D ao qual o target se refere	Índice principal
target	0 (alta) ou 1 (baixa) do candle diário de D	shift(-1) em relação às features
features_diarias	OHLCV de D-1, indicadores técnicos sobre o candle D-1	Disponíveis no fechamento de D-1
features_intraday	Agregados de 15min e 1H do pregão D-1	Calculados após fechamento de D-1
features_macro	SPX, VIX, DXY, DI, US10Y, petróleo, minério, ouro, WDO — fechamento D-1	Disponíveis após fechamento dos mercados
features_regime	Regime de mercado atual: bull/bear/lateral/juros_altos	Calculado sobre janela rolling — sem leakage
features_calendario	Evento macro agendado para D: FOMC, Payroll, COPOM, IPCA	Calendário público — disponível antes de D

3.2 Volume de Dados e Implicações

Parâmetro	Valor
Amostras por ano	~252 (dias de pregão do WIN)
Período recomendado	2015–2025 → ~2.500 amostras totais (inclui bull/bear/covid/juros altos)
Região DEV	2015–2023 → ~2.000 amostras — pesquisa, features, hiperparâmetros
Holdout DEV	2024 (~252 amostras) — seleção de threshold e configuração final
Holdout final	2025 (~250 amostras) — avaliação única, nunca tocar antes
Tamanho mínimo de treino	~500 amostras (~2 anos) por fold de walk-forward
Por que 2015?	Inclui ciclos distintos: recuperação pós-crise, impeachment, COVID, juros altos — sem esses regimes o modelo não generaliza
Implicação para modelos	Regularização agressiva obrigatória — poucos dados para modelos complexos

3.3 Checklist de Integridade

1. Zero datas duplicadas no índice de pregões
2. Zero datas de não-pregão (feriados B3, fins de semana)
3. OHLC consistente: $\text{High} \geq \max(\text{open}, \text{close})$, $\text{Low} \leq \min(\text{open}, \text{close})$
4. Volume > 0 em todos os dias de pregão
5. Cobertura dos dados externos $\geq 95\%$ — documentar dias faltantes por variável
6. Alinhamento de fuso: SPX fecha ~18h Brasília — verificar que o dado de D-1 usa o fechamento correto
7. Candles intraday cobrem pregão completo (9h–17h30 para WIN) antes de calcular agregados
8. Verificar rollover de contratos WIN — sem salto de preço artificial na data de vencimento
9. KS test de distribuição de retornos por ano — quantificar regime shifts históricos

4. Feature Engineering em Camadas

Princípio: Todas as features são calculadas sobre dados de D-1 ou anteriores. A ablação por camada é obrigatória: adicionar uma camada por vez e medir o delta de IC e AUC OOS antes de incluir a próxima.

Camada 1 — Candle Diário D-1 (Preço Puro)

```
# Estrutura do candle D-1
df['ret_close_d1']      = df['close'].pct_change()
df['body_pct_d1']       = (df['close'] - df['open']) / df['open']
df['range_pct_d1']      = (df['high'] - df['low']) / df['open']
df['close_position_d1'] = (df['close'] - df['low']) / (df['high'] - df['low'] + 1e-9)
df['upper_shadow_d1']   = (df['high'] - df[['open', 'close']].max(axis=1)) /
(df['range_pct_d1'] + 1e-9)
df['lower_shadow_d1']   = (df[['open', 'close']].min(axis=1) - df['low']) /
(df['range_pct_d1'] + 1e-9)

# Indicadores técnicos
df['atr_14']            = ta.ATR(df['high'], df['low'], df['close'], timeperiod=14)
df['atr_ratio']         = df['range_pct_d1'] / df['atr_14'] # amplitude relativa ao ATR
df['vol_20d']           = df['ret_close_d1'].rolling(20).std()
df['rsi_14']            = ta.RSI(df['close'], timeperiod=14)
df['rsi_pct_range']     = (df['rsi_14'] - 30) / 40 # posição relativa na faixa 30-70
df['macd_hist']         = ta.MACD(df['close'])[2] # histograma MACD
df['ema9_21_cross']     = (ta.EMA(df['close'], 9) - ta.EMA(df['close'], 21)) / df['close']
df['bb_pct']            = (df['close'] - ta.BBANDS(df['close'])[2]) /
(ta.BBANDS(df['close'])[0] - ta.BBANDS(df['close'])[2] + 1e-9)

# Memória de retornos recentes (série temporal para o XGBoost)
for lag in [1, 2, 3, 5, 10, 20]:
    df[f'ret_lag{lag}'] = df['ret_close_d1'].shift(lag - 1)
for w in [5, 10, 20]:
    df[f'ret_mean_{w}d'] = df['ret_close_d1'].rolling(w).mean()
    df[f'ret_std_{w}d']  = df['ret_close_d1'].rolling(w).std()
    df[f'ret_skew_{w}d'] = df['ret_close_d1'].rolling(w).skew() # assimetria recente
    df[f'range_mean_{w}d'] = df['range_pct_d1'].rolling(w).mean()
```

Camada 2 — Agregados Intraday do Dia D-1

Features calculadas sobre os candles de 15min e 1H do pregão D-1. Todos estão fechados no fechamento de D-1. Esses agregados capturam informação que o candle OHLC diário não captura — como o dia se moveu internamente, onde estava o volume, como o mercado fechou.

```
def agregar_intraday_win(df_15min, date):
    d = df_15min[df_15min['date'] == date]
```

```

# Direção e consistência do movimento intraday
ret_intra      = d['close'].pct_change().dropna()
n_alta_15      = (ret_intra > 0).mean()           # % candles de alta no dia
tendencia_intra = ret_intra.sum()                 # retorno acumulado intraday
vol_intra      = ret_intra.std()                 # volatilidade intraday
consistencia   = abs(n_alta_15 - 0.5) * 2        # 0=sem direção, 1=100%
consistente

# Comportamento do VWAP ao longo do dia
dist_vwap_fim  = (d['close'].iloc[-1] - d['vwap'].iloc[-1]) / d['vwap'].iloc[-1]
tempo_acima_vwap = (d['close'] > d['vwap']).mean()
vwap_slope     = (d['vwap'].iloc[-1] - d['vwap'].iloc[0]) / d['vwap'].iloc[0]

# Volume: onde o mercado concentrou atividade
vol_manha      = d[d['hora'] < 12]['volume'].sum() / d['volume'].sum()
vol_tarde      = d[d['hora'] >= 14]['volume'].sum() / d['volume'].sum()
close_pos      = (d['close'] - d['low']) / (d['high'] - d['low'] + 1e-9)
pressure_intra = (close_pos * d['volume']).sum() / d['volume'].sum()

# Comportamento no final do pregão – sinal de posicionamento para o dia seguinte
ret_ultima_hora = (d['close'].iloc[-1] - d['close'].iloc[-4]) / d['close'].iloc[-4]
ret_penult_hora = (d['close'].iloc[-5] - d['close'].iloc[-8]) / d['close'].iloc[-8]
aceleracao_final = ret_ultima_hora - ret_penult_hora # aceleração ou desaceleração
reversao_final   = int(np.sign(ret_ultima_hora) != np.sign(tendencia_intra))

# Amplitude e range intraday
range_max_intra = (d['high'].max() - d['low'].min()) / d['open'].iloc[0]
range_tarde     = (d[d['hora'] >= 14]['high'].max() - d[d['hora'] >= 14]['low'].min())
range_tarde     /= d['open'].iloc[0]

return { 'n_alta_15': n_alta_15, 'tendencia_intra': tendencia_intra,
        'vol_intra': vol_intra, 'consistencia_intra': consistencia,
        'dist_vwap_fim': dist_vwap_fim, 'tempo_acima_vwap': tempo_acima_vwap,
        'vwap_slope': vwap_slope, 'vol_pct_manha': vol_manha,
        'vol_pct_tarde': vol_tarde, 'pressure_intra': pressure_intra,
        'ret_ultima_hora': ret_ultima_hora, 'aceleracao_final': aceleracao_final,
        'reversao_final': reversao_final, 'range_max_intra': range_max_intra,
        'range_tarde': range_tarde }

```

Camada 3 — Gap e Contexto de Abertura

```

df['gap_d1']      = (df['open'] - df['close'].shift(1)) / df['close'].shift(1)
df['gap_vs_atr']  = df['gap_d1'] / df['atr_14']
df['gap_extremo'] = (df['gap_vs_atr'].abs() > 1.5).astype(int)
df['gap_filled']  = (np.sign(df['gap_d1']) != np.sign(df['body_pct_d1'])).astype(int)
df['gap_positivo'] = (df['gap_d1'] > 0).astype(int)

# Gap contra SPX: WIN abriu contra a direção do SPX? (sinal de pressão de normalização)
df['gap_contra_spx'] = (np.sign(df['gap_d1']) != np.sign(df['spx_ret_d1'])).astype(int)

```

Camada 4 — SPX e Risco Global (Driver Primário do WIN)

Esta é a camada mais importante para o WIN. Diferente do WDO, onde o DXY domina, o WIN é primariamente dirigido pelo apetite a risco global medido pelo SPX e VIX:

```
# SPX — driver primário, com tratamento assimétrico
df['spx_ret_d1']      = df['spx'].pct_change()
df['spx_ret_pos']     = df['spx_ret_d1'].clip(lower=0)      # contribuição de alta
df['spx_ret_neg']     = df['spx_ret_d1'].clip(upper=0)     # contribuição de queda
df['spx_slope_5d']    = df['spx'].pct_change(5)
df['spx_slope_20d']   = df['spx'].pct_change(20)
df['spx_zscore']      = df['spx_ret_d1'] / df['spx_ret_d1'].rolling(20).std()
df['spx_drawdown_60'] = df['spx'] / df['spx'].rolling(60).max() - 1
df['spx_acima_ma50']   = (df['spx'] > df['spx'].rolling(50).mean()).astype(int)
df['spx_acima_ma200'] = (df['spx'] > df['spx'].rolling(200).mean()).astype(int)

# Nasdaq — útil quando tech lidera o movimento global
df['ndaq_ret_d1']     = df['nasdaq'].pct_change()
df['ndaq_vs_spx']     = df['ndaq_ret_d1'] - df['spx_ret_d1'] # divergência Nasdaq vs
SPX

# VIX — nível e dinâmica
df['vix_nivel']       = df['vix']
df['vix_ret_d1']      = df['vix'].pct_change()
df['vix_spike']       = (df['vix_ret_d1'] > 0.15).astype(int) # spike > 15%
df['vix_ma_regime']   = pd.cut(df['vix'], bins=[0,15,20,25,35,100],
                                labels=[0,1,2,3,4]).astype(int) # 0=baixo, 4=crise
df['vix_acima_ma20']  = (df['vix'] > df['vix'].rolling(20).mean()).astype(int)
```

Camada 5 — Macro Brasil e Intermercado

Ativo	Relevância para o WIN	Features derivadas
DI Futuro	Custo de oportunidade — Selic alta compete com renda variável	ret_d1 · slope_10d · nível absoluto (acima/abaixo de 10%)
DXY	Dólar global — fluxo estrangeiro: dólar forte = saída de emergentes	ret_d1 · slope_5d · regime (acima/abaixo da MA252)
WDO / USD-BRL	Real fraco = pressão vendedora no WIN via custo de hedge do estrangeiro	ret_d1 · slope_5d · regime
US10Y / US02Y	Diferencial de juros — afeta custo de capital e valuation de ações	nível · slope · flag curva invertida
Petróleo (Brent)	Petrobras ~10% do Ibovespa — petróleo alto = suporte ao índice	ret_d1 · slope_5d

Minério de Ferro	Vale ~10% do Ibovespa — minério é o principal driver da Vale	$ret_d1 \cdot slope_5d \cdot regime$
Ouro	Safe haven — correlação inversa com risco/renda variável	ret_d1
EWZ	ETF de ações brasileiras — proxy de fluxo estrangeiro para Brasil	$ret_d1 \cdot vol_10d$

```
externals = ['di', 'dxy', 'wdo', 'us10y', 'us02y', 'oil', 'iron_ore', 'gold', 'ewz']
for ext in externals:
    df[f'{ext}_ret_d1'] = df[f'{ext}'].pct_change()
    df[f'{ext}_slope_5d'] = df[f'{ext}'].pct_change(5)
    df[f'{ext}_vol_10d'] = df[f'{ext}'].pct_change().rolling(10).std()
    df[f'{ext}_ma_regime'] = (df[f'{ext}'] >
df[f'{ext}'].rolling(252).mean()).astype(int)
    df[f'{ext}_missing'] = df[f'{ext}'].isna().astype(int)

# Divergências WIN vs drivers (sinal de desconexão ou pressão acumulada)
df['win_vs_spx'] = df['ret_close_d1'] - df['spx_ret_d1']
df['win_vs_ewz'] = df['ret_close_d1'] - df['ewz_ret_d1']
df['win_vs_oil_vale'] = df['ret_close_d1'] - (0.5*df['oil_ret_d1'] +
0.5*df['iron_ore_ret_d1'])
```

Camada 6 — Regime de Mercado (Crítica para o WIN)

Esta camada é mais importante para o WIN do que para o WDO, dada a magnitude dos regime shifts históricos. Criar features de regime explícitas que o modelo pode usar para se adaptar ao contexto:

```
# Regime de volatilidade do WIN
df['regime_vol_win'] = pd.cut(df['vol_20d'],
    bins=df['vol_20d'].quantile([0, 0.33, 0.67, 1.0]).values,
    labels=['baixa', 'media', 'alta']).astype('category')

# Regime de tendência do WIN (bull / bear / lateral)
df['ma50'] = df['close'].rolling(50).mean()
df['ma200'] = df['close'].rolling(200).mean()
df['regime_tendencia'] = np.where(df['close'] > df['ma50'],
    np.where(df['ma50'] > df['ma200'], 2, 1), # 2=bull forte,
1=bull fraco
    np.where(df['ma50'] < df['ma200'], -2, -1)) # -2=bear forte,
-1=bear fraco

# Regime de juros Brasil (afeta custo de oportunidade)
df['regime_juros_altos'] = (df['di'] > 10.0).astype(int) # DI acima de 10% = juros
altos
df['regime_di_subindo'] = (df['di'].pct_change(10) > 0).astype(int)

# Regime de risco global
df['regime_vix_alto'] = (df['vix'] >
df['vix'].rolling(252).quantile(0.75)).astype(int)
```

```

df['regime_spx_bull'] = (df['spx'] > df['spx'].rolling(200).mean()).astype(int)
df['regime_dxy_forte'] = (df['dxy'] > df['dxy'].rolling(252).mean()).astype(int)

# Regime composto – identifica o ambiente atual com um único label
# bull_global + juros_baixos + dxy_fraco = ambiente favorável para WIN
df['regime_favoravel'] = (
    (df['regime_spx_bull'] == 1) &
    (df['regime_juros_altos'] == 0) &
    (df['regime_dxy_forte'] == 0)
).astype(int)

```

Camada 7 — Calendário e Vencimento

```

df['dia_da_semana'] = df['date'].dt.dayofweek
df['semana_do_mes'] = df['date'].dt.day // 7
df['mes'] = df['date'].dt.month
df['trimestre'] = df['date'].dt.quarter

# Vencimento do WIN (última quinta-feira do mês)
df['dias_ate_venc'] = calcular_dias_ate_vencimento_win(df['date'])
df['venc_prox'] = (df['dias_ate_venc'] <= 3).astype(int)
df['semana_ciclo'] = (df['dias_ate_venc'] // 5).clip(0, 4)

# Eventos macro no DIA D (calendário público)
eventos_d = ['fomc_d', 'payroll_d', 'cpi_eua_d', 'pib_eua_d',
             'copom_d', 'ipca_d', 'pib_brasil_d', 'focus_d']

```

4.1 Seleção de Features — Protocolo de IC com Stratificação por Regime

Para o WIN, calcular o IC não apenas no dataset completo, mas também separado por regime. Uma feature pode ter IC alto no bull market e IC zero no bear market — esse é um sinal de que ela é regime-específica e precisa ser usada com cautela:

```

from scipy.stats import spearmanr

# IC global
ic_global = {}
for col in feature_candidates:
    mask = df[col].notna() & df['target'].notna()
    corr, _ = spearmanr(df.loc[mask, col], df.loc[mask, 'target'])
    ic_global[col] = abs(corr)

# IC por regime – identificar features regime-dependentes
ic_por_regime = {}
for regime in ['bull', 'bear', 'lateral', 'juros_altos']:
    df_r = df[df['regime_label'] == regime]
    ic_regime = {}
    for col in feature_candidates:

```

```
mask = df_r[col].notna() & df_r['target'].notna()
if mask.sum() < 30: continue # regime pequeno - IC não confiável
corr, _ = spearmanr(df_r.loc[mask, col], df_r.loc[mask, 'target'])
ic_regime[col] = abs(corr)
ic_por_regime[regime] = ic_regime

# Feature 'regime-estável': IC alto em  $\geq 3$  dos 4 regimes → mais robusta
# Feature 'regime-específica': IC alto apenas em 1 regime → usar com cautela
```

5. Baselines Triviais

Atenção ao viés de alta: Para o WIN, os baselines triviais têm um risco específico: em bull markets longos, 'sempre prever alta' vai ter performance financeira aparentemente boa. Por isso os baselines devem ser avaliados também separadamente por regime.

ID	Definição	O que mede
Baseline A	Sempre prever a classe majoritária (alta na maioria dos períodos)	Mede o piso trivial — qualquer modelo deve superar esse
Baseline B	Momentum: prever a mesma direção do dia anterior	Testa persistência de tendência diária
Baseline C	Mean reversion: prever direção oposta ao dia anterior	Testa se há reversão dominante dia a dia
Baseline D	Seguir o SPX: se SPX subiu ontem → prever alta do WIN	Valida o poder preditivo isolado do driver primário
Baseline E	Regra de VIX: se VIX subiu > 10% ontem → prever baixa; senão → prever alta	Valida o poder preditivo isolado do risco global
Baseline F	Buy and hold: sempre long (sem previsão)	Benchmark de retorno absoluto — o modelo precisa ter Sharpe superior ao buy and hold ajustado por drawdown

O Baseline F (buy and hold) é específico para o WIN e não existe no WDO — para um ativo com viés de alta secular, o buy and hold é um benchmark real, não apenas trivial.

6. Protocolo de Validação — Walk-Forward Purged e Regime-Aware

6.1 Arquitetura de Splits

Parâmetro	Definição
Período total	2015–2025 (~2.500 amostras)
Região DEV	2015–2023 (~2.000 amostras) — pesquisa, features, hiperparâmetros
Holdout DEV	2024 (~252 amostras) — seleção de threshold e configuração final
Holdout final	2025 (~250 amostras) — avaliação única, nunca tocar antes
Folds na região DEV	5 folds mínimo — expanding window
Tamanho mínimo de treino	~500 amostras (~2 anos)
Tamanho do teste/fold	~252 amostras (~1 ano)
Purge	5 dias entre treino e teste
Embargo	3 dias após cada fold
Requisito de regime	Cada fold de teste deve ter pelo menos 1 regime distinto representado

6.2 Análise de Regime nos Folds — Obrigatória para o WIN

Diferente do WDO, os folds do WIN podem ter composição de regime muito diferente entre si. Isso exige análise explícita da composição de regime por fold:

```
for i, fold in enumerate(folds):
    regime_composicao = fold.test['regime_label'].value_counts(normalize=True)
    print(f'Fold {i}: {regime_composicao.to_dict()}')

    # Alerta: se 1 regime > 80% do fold, o resultado é pouco generalizável
    if regime_composicao.max() > 0.80:
        print(f' ⚠ Fold {i} dominado por um regime — interpretar com cautela')

    # Avaliar métricas financeiras separadamente por regime dentro de cada fold
    for regime in fold.test['regime_label'].unique():
        subset = fold.test[fold.test['regime_label'] == regime]
        metricas = calcular_metricas_financeiras(subset['ret_liquido'])
        print(f' Regime {regime}: Sharpe={metricas["sharpe"]:.2f},
PF={metricas["profit_factor"]:.2f}')
```

6.3 Protocolo Interno de Cada Fold

10. Fatiar treino e teste cronologicamente — sem shuffle jamais
11. Fit de todo o preprocessing (scaler, imputer) APENAS no treino
12. Medir desbalanceamento de classes no treino — ajustar `scale_pos_weight`
13. Treinar o modelo APENAS no treino
14. Calibrar probabilidades na validação interna do treino (últimos 20%)
15. Selecionar threshold na validação interna — nunca no teste
16. Gerar previsões no teste de forma causal
17. Calcular métricas financeiras separadas por regime no teste
18. Armazenar probabilidades, posições e labels de regime para análise

6.4 Montagem do OOS e Cálculo de PnL

```
oos = pd.concat(fold_results).sort_index()
oos = oos[~oos.index.duplicated(keep='first')]

# PnL — recalculando após montagem, nunca somar por fold
pos_prev = oos['position'].shift(1).fillna(0)
turnover = abs(oos['position'] - pos_prev)
custo = turnover * custo_por_lado
net_pnl = oos['logret_dia'] * pos_prev - custo
equity = np.exp(net_pnl.cumsum())

# Métricas adicionais específicas para o WIN
ret_buy_hold = oos['logret_dia'].sum() # retorno do buy and hold no mesmo período
sharpe_bh = oos['logret_dia'].mean() / oos['logret_dia'].std() * np.sqrt(252)
print(f'Modelo Sharpe: {sharpe_modelo:.2f} | Buy & Hold Sharpe: {sharpe_bh:.2f}')
```

7. Modelos

7.1 Modelo 1 — XGBoost com Tratamento de Regime

```
xgb_params = {
    'n_estimators': 200,
    'max_depth': 3,
    'learning_rate': 0.01,
    'subsample': 0.6,
    'colsample_bytree': 0.6,
    'colsample_bylevel': 0.6,
    'min_child_weight': 15,
    'gamma': 0.3,
    'reg_alpha': 0.5,
    'reg_lambda': 2.0,
    'scale_pos_weight': n_baixa / n_alta, # corrigir viés de alta do WIN
    'objective': 'binary:logistic',
    'eval_metric': 'logloss',
    'random_state': 42
}
```

Diagnósticos Específicos para o WIN

- Feature importance por regime: as features mais importantes mudam entre bull e bear?
- Matriz de confusão por regime: o modelo erra mais em algum regime específico?
- Comparação com buy and hold: o modelo tem Sharpe e Calmar superiores ao buy and hold?
- Análise de drawdown: o modelo evita os grandes drawdowns do WIN (COVID, 2022)?
- Calibration plot separado por regime: probabilidades são bem calibradas em todos os regimes?

7.2 Modelo 2 — TFT

Condição: Condição de entrada: XGBoost com Sharpe OOS > 1.0 e profit factor > 1.3 em $\geq 3/5$ folds, e Sharpe superior ao buy and hold.

Tipo	Variáveis	Nota
Conhecidas no futuro	dia_da_semana, mes, trimestre, fomc_d, payroll_d, copom_d, vencimento_win	Calendário público
Observadas até D-1	OHLCV diário, agregados 15min/1H, SPX, Nasdaq, VIX, DXY, DI, WDO, US10Y, petróleo, minério, ouro, EWZ	Série temporal causal
Estáticas	Nenhuma na versão 1	Expandir com regime macro na v2

```
tft_config = {
```

```
'hidden_size':      16,  
'attention_head_size': 2,  
'dropout':          0.3,  
'hidden_continuous_size':8,  
'lstm_layers':      1,  
'max_encoder_length': 20, # lookback de 20 dias - dado diário  
'max_prediction_length': 1,  
'learning_rate':     3e-4,  
'output_size':      2,  
}
```

8. Métricas de Avaliação

8.1 Métricas Financeiras (Primárias)

```
def metricas_financeiras(ret_liquido, ret_bh=None, freq_ano=252):
    n = len(ret_liquido)
    win_rate = (ret_liquido > 0).mean()
    pf = ret_liquido[ret_liquido>0].sum() / abs(ret_liquido[ret_liquido<0].sum())
    sharpe = ret_liquido.mean() / ret_liquido.std() * np.sqrt(freq_ano)
    sortino = ret_liquido.mean() / ret_liquido[ret_liquido<0].std() *
    np.sqrt(freq_ano)
    eq = (1 + ret_liquido).cumprod()
    max_dd = (eq / eq.cummax() - 1).min()
    calmar = ret_liquido.mean() * freq_ano / abs(max_dd)
    expectancy= win_rate*ret_liquido[ret_liquido>0].mean() + (1-
    win_rate)*ret_liquido[ret_liquido<0].mean()
    cobertura = n / total_dias

    # Comparação com buy and hold — específico para o WIN
    if ret_bh is not None:
        sharpe_bh = ret_bh.mean() / ret_bh.std() * np.sqrt(freq_ano)
        return { ..., 'sharpe_vs_bh': sharpe - sharpe_bh }

    return dict(n_ops=n, win_rate=win_rate, profit_factor=pf, sharpe=sharpe,
                sortino=sortino, max_dd=max_dd, calmar=calmar,
                expectancy=expectancy, cobertura=cobertura)
```

8.2 Critérios de Aceitação OOS

Métrica	Mínimo	Rejeição	Critério
Profit factor	> 1.3	< 1.1	Rejeitar
Sharpe anualizado	> 0.8	< 0.5	Rejeitar
Sharpe vs Buy & Hold	> 0	< -0.2	Modelo perde para buy and hold — rejeitar
Win rate	> 48%	< 43%	Dado custo operacional
Max drawdown	< 20%	> 30%	Risco inaceitável
Drawdown vs B&H	< 50% do B&H max DD	Maior que B&H	Modelo piora o risco — rejeitar
N operações / fold	> 80	< 40	Estatisticamente fraco
Cobertura de dias	> 30%	< 15%	Estratégia opera pouco
Consistência de folds	≥ 3/5	≤ 2/5	Resultado concentrado

Desempenho em bear	Sharpe > 0 em folds bear	Sharpe < -0.5	Modelo faz sentido apenas em bull — rejeitar
---------------------------	--------------------------	---------------	--

9. Sinais de Alerta — Parar e Investigar

Sinal	Severidade	Ação
AUC OOS > 0.62 nos primeiros experimentos	CRÍTICO	Checar leakage — esse nível é improvável para dados diários sem vazamento
Profit factor > 2.5 sem análise de custo	CRÍTICO	Rever target, custo e lógica de execução
Feature importance dominada pelo regime_label > 40%	CRÍTICO	O modelo está apenas prevendo o regime, não a direção — leakage de regime
Desempenho colapsa em folds de bear market	ALTO	Modelo só funciona em bull — aprendeu viés de alta, não sinal real
Treino >> validação com max_depth=3	ALTO	Leakage no preprocessing — checar scaler e features calculadas no dataset completo
SPX_ret_d1 domina feature importance em todos os folds > 50%	ALTO	Modelo é essencialmente 'seguir o SPX' — comparar com Baseline D antes de comemorar
Win rate > 65%	MÉDIO	Improvável em dados financeiros diários — checar zona neutra e target
Resultado concentrado em 1–2 anos	MÉDIO	Overfitting a um período — avaliar equity curve ano a ano
Feature de regime composto domina IC	MÉDIO	Feature de regime pode estar capturando informação futura indiretamente — auditar construção

10. Roadmap de Fases

FASE 0 Fundação de Dados

Integridade e rollover antes de qualquer feature

- Pipeline de ingestão dos candles WIN diários com tratamento de rollover de contrato (eliminar salto de preço na data de vencimento)
- Pipeline de ingestão dos candles 15min e 1H para cálculo dos agregados intraday
- Alinhamento de fuso horário: SPX fecha ~18h Brasília — verificar que dado de D-1 usa o fechamento correto do dia anterior
- KS test de distribuição de retornos por ano — quantificar regime shifts 2015–2025
- Mapeamento de regimes históricos: identificar períodos bull/bear/lateral/juros_altos

Critério: zero NaN não tratados, rollover tratado, cobertura > 95%, mapeamento de regimes históricos documentado.

FASE 1 EDA e Análise de Target

Entender o ativo e validar o target antes de construir features

- Distribuição de retornos diários por ano e por regime — quantificar o viés de alta
- Autocorrelação dos retornos — o WIN tem persistência ou reversão dominante?
- Teste dos 4 targets alternativos (A, B, C, D): distribuição de classes por regime, % de zona neutra, IC com features básicas
- Análise de assimetria SPX→WIN: regressão separada para dias de alta vs queda do SPX
- IC de cada feature candidata com o target — global e por regime
- Verificação de que nenhum agregado intraday capturou informação do dia D

Critério: target fixado, viés de alta quantificado por período, ≥ 15 features com IC > 0.02, features regime-estáveis identificadas.

FASE 2 Feature Engineering

Construção incremental com ablação e verificação de regime

- Implementar as 7 camadas com verificação temporal a cada passo
- Ablação por camada: medir delta de AUC OOS e separação por regime
- Verificação específica dos agregados intraday: apenas candles do pregão D-1 fechado
- IC por regime: classificar features como regime-estáveis ou regime-específicas

- Remover features com IC global < 0.02 e correlação entre features > 0.95

Critério: features sem leakage, impacto por camada documentado, features regime-estáveis priorizadas.

FASE 3 Baselines Triviais

Piso de comparação com análise por regime

- Implementar os 6 baselines (A–F) com walk-forward e métricas financeiras
- Avaliar cada baseline separado por regime: qual baseline funciona em bull? Em bear?
- Baseline F (buy and hold) é o benchmark mais relevante — o modelo precisa ter Sharpe e Calmar superiores

Critério: todos os baselines medidos por fold e por regime, incluindo buy and hold.

FASE 4 XGBoost com Walk-Forward Regime-Aware

Primeiro modelo real com análise de regime explícita

- Walk-forward expanding com 5 folds, purge=5 dias, embargo=3 dias
- scale_pos_weight ajustado por fold para corrigir viés de alta
- Calibração isotônica de probabilidades na validação interna
- Análise de regime obrigatória: desempenho separado por bull/bear/lateral/juros_altos em cada fold
- Comparação com buy and hold no mesmo período de cada fold
- Feature importance por regime: identificar se o modelo aprende regras distintas por contexto

Critério: profit factor OOS > 1.2 , Sharpe > 0.5 , Sharpe superior ao buy and hold, desempenho positivo em folds de bear market.

FASE 5 Análise de Regime e Segmentação

Entender onde e quando o modelo funciona

- Desempenho detalhado por regime: o modelo tem valor em todos os regimes ou apenas em alguns?
- Avaliar filtro de regime: operar apenas em condições favoráveis melhora o Sharpe?

- Testar feature de regime como 'gate': modelo opera com sinal padrão em bull, com regras invertidas em bear?
- KS test entre folds para detectar regime shift e avaliar robustez da distribuição de features

Critério: análise de regime completa, Sharpe OOS > 1.0 e PF > 1.3 em $\geq 3/5$ folds, incluindo pelo menos 1 fold de bear market.

FASE 6 TFT

Modelo temporal após baseline XGBoost validado

Condição: Esta fase só começa se a Fase 5 estiver concluída com os critérios acima.

- v1: TFT com Camada 1 apenas (candle diário puro)
- v2: adicionar agregados intraday (Camada 2)
- v3: adicionar SPX/VIX e assimetria (Camada 4)
- v4: adicionar macro Brasil e intermercado completo
- v5: adicionar regime e variáveis de calendário
- Comparação a cada versão: TFT vX vs XGBoost, com análise separada por regime

11. Critérios de Transição entre Fases

Transição	Critério
Fase 0 → 1	Dados limpos, rollover tratado, cobertura > 95%, mapeamento de regimes documentado
Fase 1 → 2	Target fixado, viés de alta quantificado, ≥ 15 features com $IC > 0.02$
Fase 2 → 3	Features sem leakage, ablação documentada, features regime-estáveis identificadas
Fase 3 → 4	Todos os 6 baselines medidos por fold e por regime, incluindo buy and hold
Fase 4 → 5	XGBoost com $PF > 1.2$, Sharpe > 0.5 , Sharpe $>$ buy and hold, positivo em folds de bear
Fase 5 → 6	Análise de regime completa + Sharpe > 1.0 e $PF > 1.3$ em $\geq 3/5$ folds com bear representado

12. Checklist Anti-Leakage — Riscos Específicos do WIN

Risco	Severidade	Correção
Qualquer dado do dia D usado como feature	FATAL	Só dados de D-1 ou anteriores são permitidos
Agregado intraday usando candles do dia D	FATAL	Agregados usam APENAS candles do pregão D-1 fechado
Scaler fitado no dataset completo	FATAL	Scaler fitado APENAS no treino de cada fold
Target sem shift(-1)	FATAL	Features em D-1, target em D — shift(-1) obrigatório
Feature de regime usando retorno futuro	FATAL	Regime calculado sobre janela rolling passada — nunca inclui D
Rollover de contrato WIN criando salto	ALTO	Tratar rollover antes de calcular qualquer retorno ou feature
SPX usando fechamento errado (após D)	ALTO	SPX de D-1 = fechamento do pregão anterior, não do dia atual
IC calculado no dataset completo	ALTO	IC calculado apenas na região DEV para seleção de features
Regime label calculado com dados futuros	ALTO	MA200 e quantis rolling devem usar apenas dados disponíveis em t
Threshold selecionado no teste	ALTO	Threshold selecionado apenas na validação interna do fold
Holdout final usado para ajuste	ALTO	Qualquer ajuste baseado no holdout invalida o holdout
PnL calculado por fold e somado	MÉDIO	Recalcular após montagem do OOS completo

13. Diferenças Estruturais WIN vs WDO — Guia Rápido

Dimensão	WDO	WIN
Driver primário	DXY (câmbio global)	SPX + VIX (risco global)
Viés de classe	Aproximadamente balanceado	Viés de alta secular — tratar com scale_pos_weight

Regime shift	Moderado	Alto — bull/bear/COVID/juros são regimes radicalmente distintos
Baseline mais relevante	Baselines de gap e DXY	Buy and hold + seguir o SPX
Feature mais importante	gap_vs_atr, dxy_ret_d1	spx_ret_neg, vix_nivel, regime_tendencia
Assimetria de sinal	Simétrica (DXY sobe = WDO sobe)	Assimétrica — quedas do SPX → WIN mais intensas que altas
Rollover de contrato	Vencimento mensal WDO	Vencimento mensal WIN — tratar salto de preço
Horizonte de dados	2019+ suficiente	2015+ necessário — incluir ciclos distintos
Métrica crítica adicional	—	Sharpe vs buy and hold — modelo deve bater o índice passivo